

DeReFusion 组件消融实验报告： 组件贡献与一处权重初始化混淆

Geng

Applied Soft Computing 研究项目

2026 年 9 月

摘要

本报告记录对 DeReFusion 预测框架的一次受控组件消融。三个消融变体——woDy（仅保留基分支）、woLSTM（仅 Transformer 残差）、woTransformer（仅 LSTM 残差）——在标普 500 指数（GSPC）与 BTC/USD 两个资产上评估，预测步长 $T=24$ ，随机种子 2021，协议与配套的复现研究完全一致。共报告七次运行：三个变体 $\times$ 两个资产，外加一次 revin-DLinear 环境校准运行（其 MSE 0.07007 与参考值精确吻合）。三个发现尤为突出。第一，LSTM 是残差分支中的主导组件：去掉它在 GSPC 上改善了模型（0.06150 对 0.06230），且”仅 Transformer”变体在两个资产上均为三个变体中最优。第二，woDy 消融被权重初始化混淆：它与 revin-DLinear 基线之间的差别并非”去掉某组件”，而是丢掉了 DLinear 的权重初始化约定，在参数量完全相同的情况下，仅此一项就造成 8% 的 MSE 差距。第三，组件的价值依赖资产：完整混合模型在 BTC/USD 上胜出，而去掉 LSTM 的变体在 GSPC 上胜出。全部七次结果均由官方代码在单 CPU、单种子条件下复现得到。

关键词：金融时间序列预测；消融实验；DeReFusion；分解-残差架构；权重初始化；可逆实例归一化

1 引言

DeReFusion 将线性分解基分支（DLinear）与学习到的 LSTM-Transformer 残差分支在”直接相加融合”下结合，外层包裹可逆实例归一化（RevIN）。配套的复现研究确立了该流水线及其核心定性结论：本报告紧接着回答下一个问题：残差分支中究竟哪些组件真正支撑了模型，去掉每一个组件的代价是多少？

本研究的范围刻意收得很窄：两个资产（GSPC、BTCUSD）、一个步长（ $T=24$ ）、一个种子（2021）、三个消融变体，共七次实际运行。在此范围内，结果明确无歧义，且其中一例反直觉——最复杂的消融并非最优，而其中一个”消融”变体根本不构成干净的消融。

2 消融设计

2.1 变体

仓库在 `models/derefusion/ablation_variant/` 下提供三个消融模型。三者均保留 RevIN、DLinear 基分支与直接相加融合，仅残差分支或其有无不同：

1. **woDy**——**仅基分支**。完全移除残差分支，模型退化为 RevIN 包裹的 DLinear (4,664 参数)。
2. **woLSTM**——**Transformer 残差**。残差分支保留单层 Transformer 编码器 (4 头、FFN 4d、dropout 0.3)，去掉 LSTM (19,988 参数)。
3. **woTransformer**——**LSTM 残差**。残差分支保留 LSTM，去掉 Transformer (11,988 参数)。

作为参考，完整的 DeReFusion 残差分支 (LSTM $\rightarrow$ Transformer) 约有 28k 参数。

2.2 受控协议

每次运行使用与复现基线完全相同的协议，不作任何改动：按时间顺序 70/10/20 切分；StandardScaler 仅在训练集上拟合；每个训练模型都启用 RevIN；多变量输入、单目标输出 (MS；目标为 Close)；回看窗口 $L=96$ ；标签长度 48；Adam，学习率 10^{-4} ，批大小 32，MSE 损失；余弦调度；基于验证 MSE 的早停 (patience 5)；约 30 个 epoch；种子 2021；CPU 执行。指标为 MSE、MAE、RMSE、MAPE、MSPE、 R^2 ，均在归一化序列上计算。

实验网格为 3 个变体 $\times$ 2 个资产 = 6 次运行，外加一次校准运行，共七次。

3 环境与校准

全部运行在单台 Windows 机器上、纯 CPU 版 PyTorch 下执行，不使用 WSL、不使用 GPU。表 1 列出共享配置。

表 1: 全部消融运行的共享配置。

参数	取值
回看窗口 L / 标签长度	96 / 48
预测步长 T	24
输入通道 / 目标	4 (OHLC) / Close
d_{model}	32
移动平均核 k	25
残差 Transformer / LSTM	各 1 层 (4 头、FFN $4d$)
Dropout	0.3
优化器 / 学习率	Adam / 1×10^{-4}
批大小 / 损失	32 / MSE
调度	余弦
早停	patience 5 (验证 MSE)
随机种子	2021
设备	CPU

校准运行。按照回执协议,先执行一次已知参考答案的 `revin-DLinear` 基线: GSPC、 $T=24$ 、种子 2021。实测 MSE 为 **0.070065**, 参考值为 0.07007, 相差 6×10^{-6} , 远在接受区间 0.066–0.074 之内。环境因此确认正确, 下述消融结果可与参考表直接对比。

4 结果

4.1 实测指标

表 2 报告七次实际运行。全部数值均在归一化序列上计算, 与论文约定一致; 每个资产组内 MSE 最优者加粗。

表 2: 消融结果, 全部为本机实际运行 ($T=24$, 种子 2021, CPU)。每个资产组内 MSE 最优者加粗。MAPE/MSPE 单位为百分数。

资产	模型	MSE	MAE	RMSE	MAPE	R^2	参数量
GSPC	woLSTM	0.06150	0.18714	0.24799	5.80	0.8708	19,988
GSPC	woTransformer	0.06897	0.20742	0.26262	6.36	0.8551	11,988
GSPC	revin-DLinear	0.07007	0.21356	0.26470	6.52	0.8528	4,664
GSPC	woDy	0.07586	0.21988	0.27543	6.71	0.8406	4,664
BTCUSD	woLSTM	0.22178	0.36189	0.47094	9.32	0.8734	19,988
BTCUSD	woTransformer	0.22942	0.36869	0.47898	9.45	0.8690	11,988
BTCUSD	woDy	0.23727	0.37389	0.48711	9.58	0.8645	4,664

4.2 与完整模型的对比

表 3 将每个资产上最优的消融变体与完整 DeReFusion 及线性基线并列。完整模型与基线的参考值由合作方在同一数据与协议下报告，此处引用以作对比，并非本工作重新执行。

表 3: 最优消融与参考完整模型 / 线性基线对比 ($T=24$, 种子 2021)。MSE 越低越好。

资产	模型	MSE	R^2
GSPC	woLSTM (本机)	0.06150	0.8708
GSPC	DeReFusion (参考)	0.06230	—
GSPC	revin-DLinear (本机)	0.07007	0.8528
BTCUSD	DeReFusion (参考)	0.21797	—
BTCUSD	woLSTM (本机)	0.22178	0.8734
BTCUSD	revin-DLinear (参考)	0.22322	—





图 1: 最优消融变体 woLSTM 在 GSPC、 $T=24$ 上的复现看板（六指标雷达、误差分析、误差热力图）。

图 2: woLSTM, GSPC, $T=24$: 真值 vs. 预测窗口。

5 分析与发现

5.1 发现一：在 GSPC 上，LSTM 并非承重组件

表 2 中最清晰的结果是：去掉 LSTM 反而改善了 GSPC——woLSTM 达到 MSE 0.06150，优于完整模型的 0.06230，也优于其余所有变体。GSPC 上呈现三点排序：

$$\text{woLSTM} < \text{woTransformer} < \text{revin-DLinear} \approx \text{woDy}. \quad (1)$$

按组件解读：Transformer 对残差分支有正向贡献（相对 woLSTM，去掉它损失 0.0075 MSE），而 LSTM 贡献为负——把它加回来反而略微抬高 MSE。在近似随机游走的股指上，LSTM 的局部时序记忆在此样本量下更像是拟合噪声而非信号。

这是一个负面结果，如实报告：消融并未显示每个组件都有益。在 BTCUSD 上图景反转（见 §5.3），可见 LSTM 的负贡献是资产相关的，而非普遍规律。

5.2 发现二：woDy 消融被权重初始化混淆

woDy 本意是“纯基分支”消融，而按其构造，其前向计算与 revin-DLinear 基线完全相同：RevIN 归一化、移动平均分解、两个线性映射、相加、RevIN 反归一化。两者的参数量都恰为 4,664。然而在 GSPC 上，二者的 MSE 相差 8%（0.07586 对 0.07007）。

对两份实现的检查定位了成因。revin-DLinear 遵循 DLinear 论文的约定，把两个线性层初始化为一律取平均的核：

$$W_{se}, W_{tr} \leftarrow \frac{1}{L} \mathbf{1}_{T \times L}, \quad (2)$$

这使模型从”朴素移动平均外推”起步。woDy 对同样的层使用 PyTorch 默认的 Kaiming 均匀初始化。架构相同、参数量相同，起点不同——最优点也因此显著不同。

实际后果是：woDy 并非残差分支贡献的干净度量；它与完整模型之间 0.07586 的差距，混合了”移除残差分支”与”丢失初始化约定”两件事。干净的仅基分支消融必须沿用 DLinear 初始化；我们将其作为正确性问题标出，而不作为组件发现报告。

5.3 发现三：组件价值依赖资产

在 BTCUSD 上排序不同：woLSTM 仍居消融之首，但此时完整模型胜出——DeReFusion 0.21797 优于 woLSTM 0.22178，后者又优于基线 0.22322。在 GSPC 上有害的 LSTM，在 BTCUSD 上有益——这与该资产动态更少随机游走、因而携带可学习的时序结构相一致。

跨两个资产看，”仅 Transformer”变体比”仅 LSTM”变体更稳定；在两者并存的场合，”仅 LSTM”残差始终是两种残差设计中最弱的一个。残差分支的价值真实存在，但以资产为条件——这正是结构感知路由所要应对的情形。

5.4 参数效率

参数量与精度不同步。woLSTM (19,988 参数) 在两个资产上都优于 woTransformer (11,988) 与 woDy (4,664)，但排序并非随规模单调：woDy 与基线参数量相同却表现更差，原因正是上述混淆。在残差设计内部，更大的变体在两个资产上均胜出。

6 结论与下一步

我们在 GSPC 与 BTCUSD 上、 $T=24$ 、种子 2021，执行了七次 DeReFusion 组件消融。由此得出三点结论。

1. LSTM 并非普遍承重。去掉它改善 GSPC、却损害 BTCUSD，可见残差分支的价值依赖资产。
2. woDy 变体被权重初始化混淆，不能作为残差分支贡献的干净度量。修正方法是在该消融中恢复 DLinear 的 $1/L$ 初始化。
3. ”仅 Transformer”残差在两个资产上均为最优消融，说明在此数据规模下它是更稳健的残差设计。

下一步。 用 DLinear 初始化重跑 woDy，以获得无混淆的仅基分支数值；将网格扩展到其余步长 ($T \in \{1, 7, 12, 36\}$) 与更多资产；并增加第二个随机种子，以把 GSPC 上两处极为接近的比较 (woLSTM 与完整模型，差距 1.3%) 与种子噪声区分开。

致谢

消融模型、数据集与训练框架均来自 DeReFusion 仓库，以 MIT 许可证发布。

参考文献

- [1] C.-C. Hsieh, M.-Y. Chen, DeReFusion: A controlled comparison of soft computing fusion strategies for financial time series forecasting via a decomposition-residual architecture, *Applied Soft Computing* 203 (2026) 116252.
- [2] T. Kim, J. Kim, Y. Tae, C. Park, J. Choi, G. Choo, Reversible instance normalization for accurate time-series forecasting against distribution shift, in: *ICLR*, 2022.
- [3] A. Zeng, M. Chen, L. Zhang, Q. Xu, Are transformers effective for time series forecasting?, in: *AAAI*, 2023.